

Dans le cadre du développement de l'agent intelligent de gestion d'emails, une phase importante a consisté à mettre en place un système complet de tests automatisés ainsi que des métriques permettant d'évaluer la qualité des réponses générées par l'intelligence artificielle. Cette étape avait pour objectif de garantir la fiabilité du système, de valider son comportement et de mesurer objectivement ses performances linguistiques et fonctionnelles.

La première étape a consisté à installer l'outil de test **pytest**, qui est aujourd'hui la solution standard pour effectuer des tests automatisés en Python. L'installation a été réalisée directement dans l'environnement Conda du projet afin de garantir la compatibilité des dépendances et d'éviter les conflits entre bibliothèques. Une fois l'environnement activé avec la commande correspondante, pytest a été installé via pip. Cette étape a permis d'exécuter automatiquement les scripts de test présents dans le dossier dédié aux tests du projet.

Pour exécuter correctement les tests, il est indispensable de se positionner dans le répertoire racine du projet, c'est-à-dire celui qui contient le fichier principal de l'agent ainsi que le dossier « tests ». Cette organisation est essentielle car **pytest tests/ -s** recherche automatiquement les modules Python à partir de ce dossier racine. Une mauvaise position dans l'arborescence peut entraîner des erreurs d'importation des modules, ce qui a d'ailleurs été un problème rencontré initialement lors du développement.

Plusieurs catégories de tests ont ensuite été mises en place. Un premier type de test concerne la phase de raisonnement de l'agent. L'objectif est de vérifier que l'intelligence artificielle interprète correctement le contenu d'un email, identifie son intention principale et attribue une priorité cohérente. Cette phase est essentielle car elle conditionne l'action que l'agent doit réaliser, notamment la génération d'une réponse automatique ou le classement du message.

Un second type de test concerne la génération des réponses par le modèle de langage local utilisé dans le projet. Ce test permet de vérifier que l'agent produit effectivement une réponse exploitable à partir d'un email simulé. Il permet également de contrôler la cohérence globale de la réponse générée et d'éviter certains comportements indésirables comme des réponses vides ou incohérentes.

Un troisième type de test porte sur l'intégration avec Gmail. L'objectif est ici de vérifier que l'authentification OAuth fonctionne correctement, que l'agent est capable de lire un email réel depuis la boîte Gmail et qu'il peut envoyer une réponse automatiquement. Cette partie est particulièrement importante car elle valide l'intégration concrète du système dans un environnement réel et non uniquement simulé.

Afin d'évaluer la qualité des réponses produites par l'intelligence artificielle, un système de métriques a été ajouté au projet. Ces métriques permettent d'attribuer un score quantitatif aux réponses générées, notamment en ce qui concerne l'orthographe, la structure du message et la qualité globale du texte. Pour cela, la bibliothèque **language-tool-python** a été utilisée. Cette bibliothèque repose sur l'outil **LanguageTool**, qui nécessite l'installation préalable de Java. Il a donc été nécessaire d'installer un JDK (Java Development Kit) compatible et de vérifier son bon fonctionnement via la commande correspondante avant d'exécuter les tests.

La première métrique mise en place concerne la qualité orthographique. Elle repose sur le nombre d'erreurs détectées par **LanguageTool** rapporté au nombre total de mots dans la réponse. Cette approche permet d'obtenir un score compris entre zéro et un, où un score proche de un indique une orthographe correcte et un score faible signale une qualité linguistique insuffisante. Cette mesure est particulièrement utile car les modèles de langage peuvent parfois générer des erreurs typographiques ou grammaticales.

Une seconde métrique concerne la structure du message. Cette métrique évalue si la réponse contient les éléments essentiels d'un email professionnel, notamment une formule d'ouverture, une formule de politesse finale et une longueur minimale permettant d'assurer la clarté du message. Cette analyse permet de vérifier que l'agent adopte un comportement conforme aux standards de communication professionnelle.

Enfin, un score global a été défini en combinant ces deux métriques. Ce score global permet d'obtenir une estimation synthétique de la qualité de la réponse générée par l'agent. Il constitue un indicateur précieux pour suivre l'évolution des performances du système au cours du développement et pour identifier les axes d'amélioration.

L'analyse des résultats se fait directement lors de l'exécution des tests avec **pytest**. En ajoutant l'option d'affichage des sorties standard, il est possible d'observer les scores obtenus pour chaque réponse générée. Cela permet d'identifier rapidement d'éventuelles faiblesses du modèle, notamment en termes de qualité linguistique ou de structure des emails.

La mise en place de ces tests et métriques constitue une étape essentielle dans le développement de l'agent intelligent. Elle permet non seulement de vérifier le bon fonctionnement technique du système, mais également d'évaluer la qualité des réponses générées, ce qui est crucial dans un contexte d'automatisation de communications professionnelles. Cette démarche contribue à rendre l'agent plus fiable, plus robuste et mieux adapté à une utilisation réelle.